

Proyecto Final

Dorado-Morán Pau, 316149, p.doradomorán@ugto.mx

Introducción

Los Equipos Médicos (EM) son dispositivos fundamentales en el entorno clínico, diseñados para el diagnóstico, prevención, monitoreo y tratamiento de enfermedades. Dentro de esta categoría, los equipos electromédicos juegan un rol crucial; estos operan mediante corriente eléctrica y varían significativamente en complejidad y riesgo. Su espectro abarca desde dispositivos de uso cotidiano y bajo riesgo, como los esfigmomanómetros automáticos, hasta sistemas de soporte vital o diagnóstico avanzado, como los tomógrafos (CT) y resonadores magnéticos (MRI), los cuales demandan infraestructuras especializadas y protocolos de seguridad estrictos.

Sin embargo, existe una brecha de conocimiento significativa: para la población general, e incluso para personal no especializado, la identificación técnica de estos activos es compleja. Esta falta de familiaridad invisibiliza los peligros inherentes, provocando que los riesgos solo se hagan evidentes tras la ocurrencia de un incidente adverso (daño derivado del mal uso o fallo del equipo). Ante este escenario, surge la necesidad imperante de desarrollar herramientas que faciliten el reconocimiento de dichos equipos. Fomentar este conocimiento no solo optimiza la gestión hospitalaria, sino que es una medida preventiva esencial para salvaguardar la integridad tanto de los pacientes como de los operadores.

Objetivo

Ayudar al público en general o al personal médico sin tanto conocimiento de equipos avanzados acerca de los equipos disponibles en un espacio en concreto, con el fin de lograr inventariar de mejor forma el equipo existente en un determinado espacio hospitalario.

Justificación

La relevancia de este proyecto reside en la necesidad de facilitar una identificación ágil y precisa del equipo médico (EM), una tarea crítica tanto para el personal de salud como para la seguridad del paciente. El desconocimiento de la infraestructura tecnológica en el entorno clínico constituye una barrera significativa para la gestión hospitalaria; la incapacidad de reconocer estos activos limita el acceso a información técnica vital y entorpece la ejecución de protocolos de mantenimiento o uso.

Asimismo, esta herramienta se proyecta como un soporte técnico para ingenieros biomédicos y clínicos con experiencia limitada. Este apoyo es particularmente pertinente en el contexto mexicano, donde existe una alta tasa de importación de equipos remanufacturados provenientes de Estados Unidos. Esta situación genera una heterogeneidad tecnológica en los hospitales, donde conviven equipos antiguos de diseños robustos y poco convencionales con nuevas tecnologías que tienden a la miniaturización, como los modernos sistemas de endoscopia y laparoscopia. Esta amplia variabilidad morfológica dificulta la clasificación manual y justifica la implementación de sistemas de asistencia basados en inteligencia artificial.

Marco Teórico

De acuerdo con la Organización Mundial de la Salud (OMS), un equipo médico (EM) se define como un *"dispositivo médico que exige calibración, mantenimiento, reparación, capacitación del usuario y desmantelamiento, actividades que por lo general están a cargo de ingenieros clínicos"*. Cabe destacar que este término excluye los implantes y los dispositivos desechables o de un solo uso (1).

Para fines de este trabajo, se entenderá al EM como un dispositivo electromédico que, conforme a la norma IEC-60601 (estándar para la seguridad de equipos médicos eléctricos), se clasifica como Clase I o Clase II. Estos equipos operan con tensiones de entre 100 y 400 V a 60 Hz. Debido a estas características, el contacto accidental tanto con el prestador de servicios como con el paciente puede causar daños severos, que van desde la tetanización (parálisis muscular, dificultad respiratoria, fatiga) hasta la fibrilación ventricular (con 100 mA) o incluso el fallecimiento (con corrientes ≥ 1 A). Esto resalta la necesidad crítica de identificar y operar correctamente estos equipos. En México, las irregularidades en el funcionamiento y la infraestructura insuficiente incrementan la posibilidad de sufrir afectaciones derivadas del desconocimiento de estos dispositivos (2).

Para el desarrollo del proyecto se consideró la NOM-16-SSA3-2012, la cual establece las características mínimas de infraestructura y equipamiento de hospitales, específicamente el apéndice H relativo a la unidad quirúrgica. En esta área, la norma solicita equipos básicos como: máquina de anestesia, lámpara doble para cirugía, monitor de signos vitales, negatoscopio y unidad de electrocirugía. Dado que esta lista es limitada, se optó por complementarla con otros dispositivos para abarcar más áreas clínicas (3).

En este prototipo se utilizó un *dataset* compuesto por 11 tipos de equipos: monitor de signos vitales, máquina de anestesia, bomba de infusión, ventilador mecánico, desfibrilador, rayos X portátiles, ultrasonido, arco en C, esterilizadora de óxido de etileno y electrocardiógrafo. El conjunto de datos consta de 970 imágenes que contienen 1,243 recuadros delimitadores (*bounding boxes*). Este *dataset* se generó mediante la integración de siete conjuntos de datos de EM alojados en la plataforma Roboflow. Para garantizar la veracidad y robustez del proyecto, se comparó el modelo propuesto con uno existente en dicha plataforma. La distribución de los datos para el entrenamiento del modelo fue la siguiente: 74% (719 imágenes) para entrenamiento, 17% (165) para validación y 9% (86) para pruebas; estos porcentajes se mantuvieron para asegurar una comparación asequible.

Como parte del preprocesamiento, se autoajustó el contraste de las imágenes mediante la técnica de estiramiento de contraste (*contrast stretching*). Este proceso realiza un mapeo de los valores mínimos y máximos de intensidad de los píxeles, resultando en imágenes con detalles más definidos que facilitan la clasificación (4).

El funcionamiento del código se basa en Redes Neuronales Convolucionales (CNN), una tecnología clave en el aprendizaje automático y el *Deep Learning*. Estas redes se componen de capas de entrada, ocultas y de salida (convolucionales, de agrupamiento y totalmente conectadas). Mientras que las primeras capas detectan detalles sencillos como bordes o colores, las capas profundas reconocen elementos complejos que definen la forma del objeto. Específicamente, la capa de agrupamiento (*pooling*) reduce la dimensionalidad y la complejidad computacional, limitando la

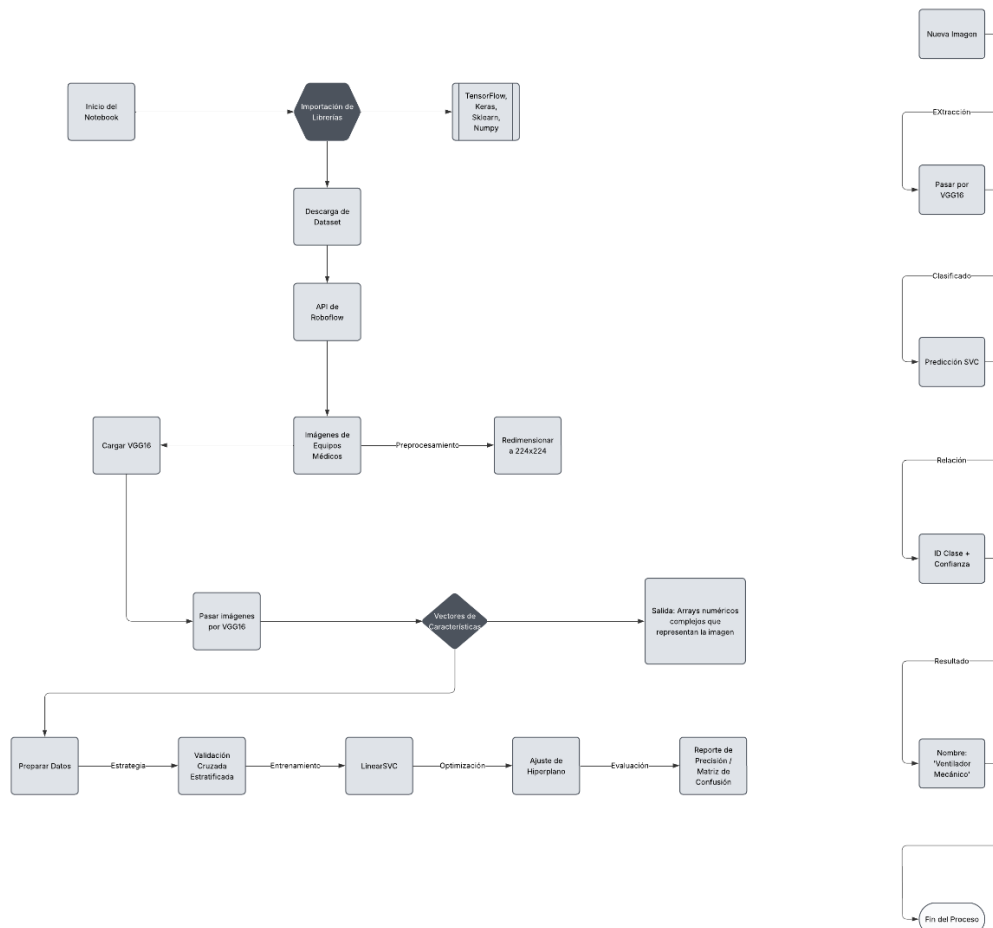
probabilidad de sobreajuste, mientras que las capas totalmente conectadas clasifican las entradas generando una probabilidad de 0 a 1 (5).

Para la extracción de características se utilizó el modelo preentrenado VGG16. Este se caracteriza por el uso de bloques de convolución de 3X3, empleando 13 capas simples y 3 capas compuestas (denso/fully connected). Esta arquitectura permite optimizar el proceso, haciéndolo menos pesado computacionalmente en comparación con otros modelos más profundos. Cabe mencionar que VGG16 requiere redimensionar las imágenes a un formato de 224X224 píxeles (6).

Posteriormente, para la clasificación de las características extraídas, se empleó una Máquina de Soporte Vectorial (SVC, por sus siglas en inglés). Este algoritmo ajusta un hiperplano que separa las clases en el espacio de características, permitiendo identificar a qué categoría corresponde cada equipo médico basándose en sus atributos (7).

Finalmente, para validar el desempeño, se utilizó la validación cruzada estratificada. Esta técnica de remuestreo permite evaluar el modelo original asegurando que la proporción de clases se mantenga en cada iteración, proceso que se ejecutó utilizando las imágenes contenidas en el conjunto de validación (8).

Diagrama de flujo de trabajo (workflow)



Actividades de programación

El proyecto se realizó por el estudiante responsable de la redacción del reporte.

Conclusión

Para el desarrollo de este prototipo se implementaron técnicas de procesamiento digital, tales como filtros de imagen, reescalamiento y el uso de extractores de características. La realización de este proyecto fue fundamental para sentar las bases del aprendizaje automatizado (*Machine Learning*), permitiendo orientar el interés hacia el desarrollo de soluciones de mayor complejidad y relevancia para la vida profesional, con un énfasis particular en la ingeniería clínica.

Entre los principales desafíos enfrentados destacó la integración de múltiples modelos (VGG16 y SVC) y la limitante en la disponibilidad de imágenes para ciertos equipos médicos específicos dentro del *dataset*. Si bien las restricciones de tiempo acotaron el alcance inicial planteado, se logró entregar un prototipo funcional susceptible a mejoras considerables en trabajos futuros.

La superación de estos obstáculos se logró mediante la investigación, la colaboración con pares y el uso de herramientas de asistencia tecnológica. Este proceso exigió un profundo razonamiento lógico para comprender la complejidad interna de los modelos, garantizando así la entrega de un desarrollo propio y evitando la simple transcripción de código.

Esperando que este reporte cumpla con los objetivos establecidos, quedo a su disposición para cualquier comentario o aclaración.

Referencias

1. Organización Mundial de la Salud. (2012). *Evaluación de tecnologías sanitarias aplicada a dispositivos médicos*. https://iris.who.int/bitstream/handle/10665/44820/9789243501536_spa.pdf
2. Comisión Electrotécnica Internacional. (2012). *Equipos electromédicos - Parte 1: Requisitos generales para la seguridad básica y el rendimiento esencial* (IEC 60601-1:2005 + COR1:2006 + COR2:2007 + A1:2012). <https://www.iec.ch>
3. Gobierno de México, Secretaría de Salud. (2012, 13 de septiembre). *Norma Oficial Mexicana NOM-016-SSA3-2012, Que establece las características mínimas de infraestructura y equipamiento de hospitales y consultorios de atención médica especializada*. Diario Oficial de la Federación. <https://www.gob.mx/cms/uploads/attachment/file/512104/NOM-016-SSA3-2012.pdf>
4. The Ultimate Guide. (2023, 21 septiembre). *The ultimate guide to contrast stretching in image processing*. Number Analytics. <https://www.numberanalytics.com/blog/ultimate-guide-contrast-stretching-image-processing#:~:text=Contrast%20stretching%20is%20a%20technique%20used%20to%20enhance,values%2C%20to%20create%20a%20more%20visually%20appealing%20image.>
5. Aly, S. A., Khalaf, H., Yacout, G. A., & Samy, A. (2024, 25-27 marzo). *Medical image enhancement using color and contrast stretching technique for heart disease* [Ponencia de conferencia]. 2024 4th International Conference on Electronic Engineering (ICEEM), El Cairo, Egipto. <https://ieeexplore.ieee.org/document/10768978>
6. Pérez-Cruz, J. C., Morales-Rosales, L. A., Del Moral-Hernández, E., Vigueras-Zuñiga, M. O., & Alarcón-Aquino, V. (2024). *Optimal contrast stretching on color fundus images for deep learning models in diabetic retinopathy diagnosis*. IEEE Access, 12, 25076-25098. <https://doi.org/10.1109/ACCESS.2024.3366257>

7. Scharcanski, J., & Cavalcanti, P. G. (2016). *Adaptive image enhancement and unsupervised segmentability evaluation for detecting skin lesions* [Ponencia de conferencia]. 2016 IEEE International Conference on Image Processing (ICIP), Phoenix, AZ, USA. <https://ieeexplore.ieee.org/document/7752782>
8. DataScientest. (2023, 25 octubre). *Cross-validation: Definición e importancia*. <https://datascientest.com/es/cross-validation-definicion-e-importancia>

*Nota

Para garantizar la correcta ortografía del texto se utilizó Gemini Ai